

Detección temprana de diabetes mediante modelos de clasificación de aprendizaje supervisado.

Por: Sergio Bouchán Catalán



Índice

Descripción del conjunto de datos.....	3
Análisis	4
Modelado	7
Separación de variables	7
Preprocesamiento.....	7
Regresión Logística	7
SVC	9
Árbol de Decisión.....	11
Comparativa y selección del mejor modelo	13
Optimización del modelo SVC.....	13
Conclusiones.....	16
Referencias	16

Objetivo

Actualmente, la diabetes es una de las enfermedades más comunes entre personas de cualquier edad; de acuerdo con la Organización Mundial de la Salud, el número de personas que viven con diabetes pasó de 200 millones en 1990 a 830 millones en 2022 y más de la mitad de estas personas, no tomaban medicación alguna contra la enfermedad. Muchos pacientes viven con esta enfermedad sin saberlo y la detectan hasta que está muy avanzada.

El objetivo de este proyecto es utilizar la información clínica y biométrica de un paciente para detectar de manera temprana si presenta o no diabetes, mediante la comparación de tres modelos de clasificación de aprendizaje supervisado: Regresión Logística, Máquina de Soporte Vectorial y Árbol de Decisión.

Descripción del conjunto de datos

El conjunto cuenta con 9 columnas y 768 filas. En la tabla 1 se muestra una descripción de las variables contenidas en el dataset [Pima Indians Diabetes Database](#); estas variables representan características clínicas y biométricas de los pacientes que los modelos usaran como predictores para identificar los patrones asociados con la presencia o ausencia de diabetes.

Tabla 1: Descripción de variables.

Variable	Tipo de variable	Descripción
Pregnancies	Numérica entera	Número de embarazos, puede estar relacionado con cambios metabólicos asociados a riesgo de diabetes.
Glucose	Numérica entera	Nivel de glucosa, concentración de azúcar libre en la sangre, uno de los indicadores más importantes.
Blood Pressure	Numérica entera	Presión arterial diastólica, medida en milímetros de mercurio (mm Hg).
Skin Thickness	Numérica entera	Espesor del pliegue cutáneo del tríceps en milímetros (mm), es un indicador indirecto de la grasa corporal.
Insulin	Numérica entera	Insulina sérica en milunidades internacionales por mililitro (mU/ml), la insulina es una hormona fundamental en la regulación de la glucosa.
BMI	Numérica decimal	Índice de masa corporal en kilogramos por metros cuadrados (kg/m^2).
Diabetes Pedigree Function	Numérica decimal	Función del pedigrí de la diabetes: estima la probabilidad de desarrollar diabetes según las relaciones genéticas con parientes afectados.
Age	Numérica entera	Edad.
Outcome (Variable objetivo)	Numérica binaria	Diagnóstico: 1 para las personas con diabetes, 0 para las personas sin diabetes.

Análisis

Se realizó un análisis concreto para identificar los aspectos generales más sobresalientes del conjunto de datos y la existencia de anomalías. Primero se realizó el conteo de valores en la variable objetivo, como se muestra en la figura 1, el 65.1% de los participantes no tienen diabetes, el 34.9% sí presentan la enfermedad.




Figura 1: Gráfico de barras de la presencia de diabetes en los participantes.

Se realizó un resumen estadístico de las variables en el dataset, los resultados se muestran en la tabla 2:

Tabla 2: Resumen estadístico.

	Embarazos	Glucosa	Presión arterial	Espesor cutáneo	Insulina	IMC	Pedigrí de función de diabetes	Age
media	3.85	120.89	69.11	20.54	79.8	31.99	0.47	33.24
STD	3.37	31.97	19.36	15.95	115.24	7.88	0.33	11.76
min	0	0	0	0	0	0	0.08	21
25%	1	99	62	0	0	27.3	0.24	24
50%	3	117	72	23	30.5	32	0.37	29
75%	6	140.25	80	32	127.25	36.6	0.63	41
máx	17	199	122	99	846	67.1	2.42	81

El dataset no contiene valores nulos, sin embargo, las variables del nivel de glucosa, presión arterial, espesor cutáneo, nivel de insulina e índice de masa corporal, poseen datos con el valor cero, esto no es posible, por lo que, fueron procesadas después del Split de los conjuntos de entrenamiento y pruebas para el modelo. En la figura 2 se muestra un boxplot de cada una de estas variables más el Pedigrí de función de diabetes para detectar la presencia de valores atípicos y así decidir cuál es el mejor método de imputación de los valores erróneos.




Figura 2: Boxplot de columnas con valores erróneos.

Se presentan las siguientes observaciones importantes:

- En la variable de **espesor cutáneo**, el valor del primer cuartil es cero, lo que sugiere una cantidad considerable de datos faltantes codificados erróneamente como cero.
- En el caso de la **insulina** se presenta la misma situación que con el espesor cutáneo, pero además existe una fuerte asimetría positiva con una gran presencia de valores atípicos, algunos llegando a ser bastante extremos.

Debido a la presencia de asimetrías, datos atípicos y valores extremos en varias variables, se optó por utilizar la mediana como método de imputación para los valores asignados erróneamente como cero, debido a que, la mediana es una medida robusta que reduce la influencia de observaciones extremas sobre los valores imputados.

Se calculó la matriz de correlación (figura 3) para evaluar la intensidad y dirección de las relaciones lineales entre las variables del conjunto y la presencia de diabetes; se detectó que el nivel de glucosa tiene la correlación positiva más alta con ($r = 0.49$), lo que indica que niveles elevados de glucosa pueden estar asociados con una mayor probabilidad de padecer la enfermedad; aunque, en general ninguna de las variables presentó correlaciones fuertes con la variable objetivo ($r > 0.70$), lo que sugiere que la predicción depende de la combinación de múltiples características y no de un único predictor, esto justifica la utilización de modelos de aprendizaje supervisado capaces de capturar relaciones complejas entre las variables.




Figura 3: correlación entre variables.

El análisis exploratorio realizado permitió identificar valores erróneamente representados, así como la presencia de datos atípicos y establecer la correlación entre variables; estos hallazgos proporcionan evidencia y justificación para proceder con la etapa de preprocesamiento y el entrenamiento de modelos predictivos.

Modelado

Separación de variables

Se separaron las variables primero en 2 conjuntos: “X” para las variables independientes y “y” para la variable objetivo, la que se busca predecir. En la variable “X” se incluyeron los embarazos, nivel de glucosa, presión arterial, espesor cutáneo, nivel de insulina, IMC, Pedigrí de función de diabetes y edad; mientras que, en “y” únicamente se maneja el resultado. Posteriormente, las variables fueron separadas en conjuntos de entrenamiento y de pruebas

Preprocesamiento

Se tenían valores faltantes y en escalas diferentes, por lo que, antes de pasar a la construcción y entrenamiento de los modelos, dentro de un Pipeline se realizó la imputación de los datos con la mediana y después, se estandarizaron usando un Standard Scaler principalmente para los modelos de Regresión y SVM que son sensibles a la escala de los datos. Se realizó el preprocesamiento dentro de un Pipeline para evitar fuga de información en el entrenamiento del modelo. A continuación, se presentan los modelos base utilizados, el de mayor rendimiento fue el elegido para perfeccionar y tomar como modelo final para el proyecto.

Regresión Logística

El primer modelo implementado fue el de Regresión Logística, se manejaron sus hiperparámetros por defecto y se incluyó dentro de un Pipeline para garantizar un flujo de trabajo reproducible y evitar la fuga de información. Tras entrenar el modelo y realizar predicciones, se obtuvo la matriz de confusión que se muestra en la figura 4.




Figura 4: matriz de confusión del modelo de regresión logística.

Se ocuparon las métricas de *precision*, *recall*, *f1-score* y *accuracy* para evaluar el modelo. En la tabla 3 se muestran los resultados de las métricas tanto en entrenamiento como en pruebas para poder detectar si se presenta un sobreajuste en el modelo.

Tabla 3: Métricas de evaluación en los conjuntos de entrenamiento y pruebas del modelo de regresión logística.

Métrica	Categoría	Entrenamiento	Pruebas
<i>Precision</i>	0	0.81	0.75
	1	0.77	0.60
<i>Recall</i>	0	0.91	0.82
	1	0.59	0.50
<i>F1-Score</i>	0	0.85	0.78
	1	0.67	0.55
<i>Accuracy</i>	General	0.80	0.71

Se graficó la curva ROC (figura 5) para evaluar el modelo en todos los umbrales de decisión posibles.




Figura 5: curva ROC del modelo de regresión logística.

El modelo de regresión logística predijo correctamente 82 pacientes sin diabetes y 27 con diabetes; 18 casos fueron catalogados como falsos positivos (se clasificaron como diabéticos sin serlo) y 27 como falsos negativos (clasificados como sanos, pero en realidad son diabéticos).

A continuación, se enlista un breve análisis de cada una de las métricas evaluadas en la tabla 3 para el conjunto de pruebas y con enfoque a los casos con diabetes:

- Una exactitud (*accuracy*) de 0.71 significa que el modelo de regresión logística clasificó correctamente el 71% de las observaciones.
- La precisión de la clase positiva (1) fue de 0.60, entonces, el 60% de los pacientes clasificados por el modelo como diabéticos realmente presentan esta enfermedad.
- El *recall* alcanzó un valor de 0.50, indicando que el modelo logró identificar correctamente solo a la mitad de los pacientes con diabetes presentes en el conjunto de prueba. Esta métrica es de especial relevancia en este caso, ya que, el no detectar correctamente la enfermedad retrasa su tratamiento, lo que puede causar que empeore con el tiempo.
- El *F1-score* fue de 0.55, reflejando un equilibrio moderado entre *precision* y *recall*.

Por último, la curva ROC del conjunto de pruebas confirmó que el modelo tiene una capacidad discriminativa adecuada, con un área bajo la curva de 0.813 que indica que, el algoritmo puede distinguir correctamente entre pacientes con y sin diabetes en aproximadamente el 81% de las comparaciones aleatorias entre ambas clases, sin embargo, de acuerdo con las métricas y la matriz de confusión, al modelo le resulta considerablemente más sencillo detectar a los casos negativos, lo que, si bien, es útil, se considera que debería darse prioridad a la detección de casos positivos, ya que, el objetivo de este proyecto es apoyar con la detección temprana de la enfermedad e iniciar el tratamiento lo antes posible.

En general, la principal limitante del modelo de regresión logística es que supone una relación aproximadamente lineal entre las variables predictoras y el logaritmo de las probabilidades, por lo que, se le dificulta captar relaciones altamente no lineales.

SVC

El siguiente modelo evaluado fue la máquina de soporte vectorial para clasificación (SVC), nuevamente se manejaron hiperparámetros por defecto y el modelo se incluyó dentro de un Pipeline. En la figura 6 se muestra la matriz de confusión con los resultados obtenidos.




Figura 6: matriz de confusión del modelo SVC.

Se ocuparon las mismas métricas para evaluar el modelo y los resultados se muestran en la tabla 4. En la figura 7 se muestra la curva ROC de este modelo.

Tabla 4: Métricas de evaluación en los conjuntos de entrenamiento y pruebas del modelo SVC.

Métrica	Categoría	Entrenamiento	Pruebas
<i>Precision</i>	0	0.84	0.78
	1	0.84	0.65
<i>Recall</i>	0	0.93	0.84
	1	0.67	0.56
<i>F1-Score</i>	0	0.88	0.81
	1	0.75	0.60
<i>Accuracy</i>	General	0.84	0.74




Figura 7: curva ROC del modelo SVC.

El modelo SVC predijo correctamente 84 pacientes sin diabetes y 30 con diabetes; 16 casos fueron catalogados como falsos positivos y 24 como falsos negativos.

A continuación, se muestra el análisis de los resultados obtenidos en la tabla 4 para el conjunto de pruebas y con enfoque a los casos con diabetes:

- Exactitud (*accuracy*) de 0.74, el modelo SVC clasificó correctamente el 74% de las observaciones.
- Precisión de la clase positiva (1) de 0.65, el 65% de los pacientes clasificados por el modelo como diabéticos realmente lo son.
- *Recall* de 0.56, el modelo logró identificar correctamente a poco más de la mitad de los pacientes con diabetes presentes en el conjunto de prueba.
- *F1-score* de 0.60.

La curva ROC del conjunto de pruebas sugiere que el modelo tiene una capacidad discriminativa adecuada, con un área bajo la curva de 0.796, entonces, el algoritmo puede distinguir correctamente entre pacientes con y sin diabetes en aproximadamente el 80% de las comparaciones aleatorias entre ambas clases y nuevamente, de acuerdo con las métricas y la matriz de confusión, al modelo le resulta más sencillo detectar a los casos negativos, aunque hay un ligero incremento en la detección de pacientes diabéticos.

En el modelo SVC, las principales limitaciones que se tienen son su alta dependencia a la elección de los hiperparámetros correctos, su sensibilidad a valores atípicos y su falta de estimación directa de las probabilidades de pertenencia de clase, lo cual incrementa significativamente el tiempo de entrenamiento y es menos eficiente que calcular probabilidades en otros modelos

Árbol de Decisión

El último modelo base evaluado fue el árbol de decisión. En la figura 8 se muestra la matriz de confusión con los resultados obtenidos.




Figura 8: matriz de confusión del árbol de decisión.

Se ocuparon las mismas métricas para la evaluación del modelo y los resultados se muestran en la tabla 5. En la figura 9 se muestra la curva ROC del modelo.

Tabla 5: Métricas de evaluación en los conjuntos de entrenamiento y pruebas del árbol de decisiones.

Métrica	Categoría	Entrenamiento	Pruebas
<i>Precision</i>	0	1.00	0.74
	1	1.00	0.55
<i>Recall</i>	0	1.00	0.79
	1	1.00	0.48
<i>F1-Score</i>	0	1.00	0.76
	1	1.00	0.51
<i>Accuracy</i>	General	1.00	0.68




Figura 9: curva ROC del árbol de decisiones.

El árbol predijo correctamente a 79 pacientes sin diabetes y a 26 diabéticos; 21 casos fueron falsos positivos y 28 falsos negativos.

A continuación, se muestra el análisis de los resultados obtenidos en la tabla 5 para el conjunto de pruebas con enfoque a los casos de pacientes diabéticos:

- Exactitud (*accuracy*): 0.68, el modelo clasificó correctamente el 68% de las observaciones.
- Precisión: 0.55, el 55% de los pacientes clasificados por el modelo como diabéticos realmente padecen la enfermedad.
- Recall: 0.48, el modelo logró identificar correctamente a poco menos de la mitad de los pacientes con diabetes.
- *F1-score* de 0.51.

El modelo tiene una capacidad discriminativa un poco más pobre que los modelos anteriores, el algoritmo solo distingue entre pacientes diabéticos y sanos en el 64% de las comparaciones aleatorias entre clases y lo que más resalta en este caso, es un claro sobreajuste del modelo, ya que, memorizó perfectamente los datos del conjunto de entrenamiento, creó reglas muy específicas para ellos y al momento de ingresar datos nuevos, la calidad del modelo bajó considerablemente y es justo esta la mayor desventaja del árbol de decisiones, que, si no se controla su crecimiento con hiperparámetros como la profundidad máxima, el número mínimo de muestras por nodo y el mínimo de muestras por hoja, el árbol va a crecer hasta que catalogue perfectamente a cada una de las muestras del conjunto de entrenamiento, pero fallará cuando se le ingresen nuevos datos.

Comparativa y selección del mejor modelo

En la tabla 6 se presenta una comparativa entre los resultados de los modelos en el conjunto de entrenamiento, con enfoque a los casos positivos que corresponden a los pacientes diabéticos.

Tabla 6: Comparación entre modelos.

Modelo	Positivos detectados	Falsos negativos	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Regresión Logística	27	27	0.71	0.60	0.50	0.55	0.813
SVC	30	24	0.74	0.65	0.56	0.60	0.796
Árbol	26	28	0.68	0.55	0.48	0.51	0.636

Con base en el objetivo del proyecto, lo que se pretende es apoyar a la detección temprana de la enfermedad para que sea tratada lo antes posible, entonces lo que se busca es maximizar la predicción de casos positivos y evitar falsos negativos, no es deseable que una persona sea catalogada como sana cuando en realidad tiene diabetes, por ello, el modelo elegido para optimizarlo y entregar una versión final a usar para el proyecto es la máquina de soporte vectorial (SVC) que fue la que tuvo las mejores métricas, la mayor cantidad de positivos detectados y la menor cantidad de falsos negativos, además, no tiene tanta diferencia en el AUC con respecto a la regresión logística y no está exageradamente sobreajustado como el árbol de decisiones.

Optimización del modelo SVC

Para optimizar el modelo se recurrió a una red de hiperparámetros con validación cruzada estratificada para posteriormente entrenar el modelo con los mejores hiperparámetros; primero se había dado prioridad al *recall*, sin embargo, aunque el modelo bajaba drásticamente la cantidad de falsos negativos, una gran cantidad de datos eran catalogados ahora como falsos positivos y en este caso, no es útil tampoco tener un algoritmo que prácticamente clasifique a todos los pacientes como diabéticos, porque esto significaría que se tendrían que realizar estudios de seguimiento a los pacientes y si resultan no ser diabéticos, sería una pérdida de recursos tanto económicos y de tiempo; por ello, se optó por priorizar la métrica *F1* para que el modelo fuera más balanceado.

. En la tabla 7 se presentan los resultados de las métricas evaluadas tanto en entrenamiento como en pruebas; en la figura 10 se muestra la matriz de confusión que se obtuvo con el modelo SVC optimizado y en la figura 11 se observa la curva ROC-AUC del algoritmo.

Tabla 7: Métricas de evaluación en los conjuntos de entrenamiento y pruebas del modelo SVC optimizado.

Métrica	Categoría	Entrenamiento	Pruebas
<i>Precision</i>	0	0.89	0.84
	1	0.67	0.58
<i>Recall</i>	0	0.78	0.71
	1	0.82	0.74
<i>F1-Score</i>	0	0.83	0.77
	1	0.73	0.65
<i>Accuracy</i>	General	0.79	0.72

Matriz de Confusión — Máquina de Soporte Vectorial Optimizada




Figura 10: matriz de confusión del modelo SVC optimizado.

Curva ROC - Máquina de Soporte Vectorial Optimizada




Figura 11: curva ROC del modelo SVC optimizado.

En la tabla 8 se muestra la comparativa entre los resultados en el conjunto de entrenamiento, del modelo base de la máquina de soporte vectorial y el algoritmo con hiperparámetros optimizados, con enfoque a los casos positivos que corresponden a los pacientes diabéticos.

Tabla 8: Comparación entre modelos SVC.

Modelo	Positivos detectados	Falsos negativos	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	ROC-AUC
SVC Base	30	24	0.74	0.65	0.56	0.60	0.796
SVC Optimizado	40	14	0.72	0.58	0.74	0.65	0.807

El modelo SVC optimizado predijo correctamente 71 pacientes sin diabetes y 40 con diabetes; 29 casos fueron catalogados como falsos positivos (clasificados como diabéticos sin serlo) y 14 como falsos negativos, siendo este último dato un cambio bastante favorable, ya que el modelo original tenía 24 falsos negativos y el mejorado solo tiene 14 pacientes que predijo erróneamente como sanos.

A continuación, se realiza el análisis de cada una de las métricas evaluadas en la tabla 8 para el conjunto de pruebas y con enfoque a los casos con diabetes:

- El modelo optimizado tiene una exactitud (*accuracy*) de 0.72, lo que, significa que el modelo clasificó correctamente el 72% de las observaciones, un valor un poco menor al del modelo base, pero no es una caída drástica.
- La precisión de la clase positiva (1) fue de 0.58, por lo tanto, el 58% de los pacientes clasificados por el modelo como diabéticos realmente presentan esta enfermedad, de nuevo, el modelo optimizado presenta menor precisión comparado con el 65% del algoritmo base, sin embargo, esto no es necesariamente malo, significa que, el modelo prefiere equivocarse categorizando a un paciente como diabético que dejar escapar a un paciente enfermo catalogándolo como sano.
- El *recall* alcanzó un valor de 0.74, un aumento con respecto al 0.56 que tenía el modelo base, gracias a este aumento, el modelo ahora detectó correctamente al 74% de los pacientes diabéticos en el conjunto, prácticamente tres cuartos de la muestra.
- El *F1-score* fue de 0.65, reflejando un equilibrio moderado entre *precision* y *recall* mejor que el del modelo base.

Por último, la curva ROC del conjunto de pruebas confirmó que el modelo tiene una capacidad discriminativa adecuada, con un área bajo la curva de 0.807 que indica que, el algoritmo puede distinguir correctamente entre pacientes con y sin diabetes en aproximadamente el 81% de las comparaciones aleatorias entre ambas clases, prácticamente igual que el modelo de regresión logística que fue el de mejor AUC.

Conclusiones

Retomando el objetivo del proyecto, se utilizó la información clínica y biométrica de los pacientes para construir tres modelos de clasificación de aprendizaje supervisado: regresión logística, máquina de soporte vectorial y árbol de decisión que ayudaran a determinar si un paciente padece o no diabetes. De estos tres modelos base, el más apto para el proyecto fue la Máquina de Soporte Vectorial (SVC), por lo que, se tomó ese algoritmo y fue optimizado considerando el objetivo del proyecto.

El modelo SVC optimizado presentó una ligera disminución en algunas métricas con respecto al modelo base, pero incrementó en gran medida el recall de la clase positiva de 0.56 a 0.74, reduciendo los falsos negativos de 24 a 14 pacientes y dado que el objetivo principal del estudio es apoyar a la detección temprana de diabetes, se consideró que esta mejora representa un beneficio clínicamente más relevante que la pérdida moderada de las otras métricas, ya que, con el modelo optimizado hay menos pacientes que fueron detectados como sanos pero que en realidad son diabéticos, además, el minimizar los falsos negativos en aplicaciones relacionadas con la salud, es fundamental para favorecer la detección temprana de enfermedades y apoyar a los pacientes y médicos en la toma de decisiones clínicas.

Referencias

- Organización Mundial de la Salud. (s.f.). *Diabetes*. <https://www.who.int/es/news-room/fact-sheets/detail/diabetes>.
- UCI Machine Learning. (s.f.). *Pima Indians Diabetes Database [Conjunto de datos]*. <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>.